Charades-CG v2 | 官方组合泛化 + 跨视频负例

保留官方 Test-Trivial / Novel-Composition 身份 · 独立单划分 C3_CG

Unseen 语义划分
1 组 · C3_CG

每组 Test 正例 · 事件存在
5,674

每组 Test 负例 · 标注缺席
5,674

样本来源

正例：官方 Train 与两个测试子集。
异常、越界时间窗直接删除；不包含 Novel-Word。

负例设计

每个正例查询 → 一个跨视频负例

同划分内，CLIP 比较查询与视频全部正描述。
每视频取最高相似度，从最低一半随机采样。
排除原视频及同句；两个 Test 共用候选池。

哪些查询属于 Unseen?

训练	官方 Train → Seen
Seen	官方 Test-Trivial
Unseen	官方 Novel-Composition

S/U 身份继承官方；没有改成 A1–C2 规则

实际使用的样本数 · 单位：视频–查询配对

每组 Test：2,589 个视频 / 片段

划分	Train	Seen Val	Test S+	Test S−	Test U+	Test U−
C3_CG	12,684	1,368	2,684	2,684	2,990	2,990

Seen Test · Test-Trivial

2,684 正例 + 2,684 负例 = 5,368 条

Unseen Test · Novel-Composition

2,990 正例 + 2,990 负例 = 5,980 条

S = Seen，U = Unseen；+ 有时间窗，− 空时间窗。训练与选模只用 Seen。

负例借鉴 Moment of Untruth §3.3；Seen Test、Unseen Test 各自正负 1:1。